




Aula 1: Introdução à Ciência de Dados com Python e Pandas



**Prof. Dr. Danilo César
Pereira**



BEM-VINDOS À ERA DOS INSIGHTS.

Esta aula marca o início da sua jornada no fascinante mundo da análise de dados, inteligência artificial e aprendizado de máquina.

Prepare-se para transformar dados em insights valiosos.



Bem-vindo à Ciência de Dados



Início da Jornada

É com grande entusiasmo que iniciamos esta disciplina transformadora. Você está prestes a adquirir habilidades extremamente valorizadas no mercado de trabalho contemporâneo.

O que você vai dominar:

- **Programação:** Criação de algoritmos e automação.
- **Estatística:** Análise rigorosa e modelagem de dados.
- **Negócios:** Solução de problemas reais e decisões estratégicas.

CRESCIMENTO DO MERCADO

+35%

Ao Ano

A demanda por cientistas de dados é uma das que mais crescem no mundo tecnológico atual, segundo dados do LinkedIn.

Estrutura da Aula (90 min)



Apresentação

20 Minutos

Introdução e contextualização sobre o que é ciência de dados.



Teoria Essencial

30 Minutos

Exploração aprofundada dos fundamentos teóricos indispensáveis.



Demonstração Prática

25 Minutos

Configuração do Google Colab e escrita do primeiro código em Python.

Atividade Final Guiada

Exploração de Datasets Ativa

Análise prática na prática usando dados reais nos últimos 15 minutos.

15 MINUTOS RESTANTES

Objetivos da Aula e Prática



Objetivos Estratégicos

Ao final desta aula você será capaz de:

Compreensão Conceitual: Entender o conceito de ciência de dados e sua importância estratégica no mundo de hoje.

Pirâmide DIKW: Saber diferenciar claramente dados, informação, conhecimento e sabedoria.

Estudo de Casos Reais: Identificar aplicações de dados em negócios de empresas como Netflix, Amazon e Spotify.

Desenvolvimento Prático

Suas metas de aplicação prática:

Google Colab: Configurar e utilizar o ambiente de desenvolvimento em nuvem com facilidade.

Primeiro Notebook: Aprender a criar, organizar e rodar códigos em seu primeiro notebook Python.

Análise com Pandas e Matplotlib: Explorar datasets reais utilizando código de análise inicial e visualização gráfica.

Destaque Interativo / Quebra-Gelo Vamos nos conhecer!

Entendendo o nosso grupo

Antes de mergulharmos no conteúdo, queremos entender melhor nosso grupo utilizando uma ferramenta interativa.

Esta dinâmica nos ajudará a calibrar o ritmo das aulas e criar conexões valiosas entre os estudantes para colaboração mútua.

O que queremos mapear:

- ◆ **Nível de experiência prévia com programação:**
Nenhuma, básica, intermediária ou avançada.
- ◆ **Por que você escolheu esta disciplina?**
- ◆ **Quais são as suas expectativas de aprendizado?**
- ◆ **Quais áreas de aplicação de dados mais te interessam?**


Algoritmo de Recomendação da Netflix



80%

Das visualizações vêm do algoritmo

O sistema mapeia padrões complexos: o que você assiste, pausa, abandona, o tempo gasto em cada título, avaliações diretas e o comportamento de usuários semelhantes.



Impacto em Escala Global

+500 Milhões de Eventos Diários

O processamento massivo de dados para personalização em tempo real gera uma economia anual de **US\$ 1 bilhão** em retenção de assinantes, consolidando o poder estratégico da ciência de dados.

Previsão de Demanda e Logística na Amazon



Ciência de Dados em Ação

Previsão de Demanda

Otimização de estoques de forma proativa e integrada em centros de distribuição globalmente.

Preço Dinâmico

Ajuste diário de milhares de produtos baseando-se em concorrência, níveis de estoque e comportamento de compra.

Algoritmo de Recomendação **(35% das Vendas)**

Sistema personalizado de sugestão de produtos que direciona mais de um terço do faturamento total da empresa.

Otimização Logística **(+29% de Conversão)**

Previsão exata de rotas eficientes e personalização da jornada de entrega impulsionada inteiramente por dados.

Playlists Personalizadas "Descobertas Semanais"



COMO FUNCIONA O PIPELINE DO SPOTIFY

Inteligência de Recomendação para 500M+ de Usuários

Atributos de Áudio: O sistema utiliza algoritmos para analisar características técnicas fundamentais das faixas, tais como ritmo, energia, valência (positividade musical) e dançabilidade.

Clusterização & Filtragem: A plataforma agrupa usuários por gostos similares e aplica filtragem colaborativa para mapear e identificar padrões ocultos de comportamento entre ouvintes.

Processamento de Linguagem Natural: Técnicas avançadas de NLP analisam letras de músicas, metadados e conversas na web para enriquecer a precisão contextual da playlist.

MÉTRICA DE IMPACTO

+30%

Tempo Total de Audição

Como resultado prático do algoritmo, os usuários engajados passam muito mais tempo na plataforma, provando o valor imediato da personalização automatizada.

Dados em Larga Escala nas Operações



UBER

Aplica **preço dinâmico** baseado em oferta e demanda em tempo real nas cidades.

Prevê congestionamentos complexos utilizando modelos avançados de **machine learning**.

Otimiza constantemente o **matching** entre motorista e passageiro para reduzir severamente o tempo de espera.

IFOOD

Prevê o **tempo de entrega** considerando o trânsito atual, tempo de preparo do restaurante e rotas otimizadas.

Recomenda pratos e estabelecimentos de forma altamente personalizada baseando-se no **histórico de consumo** de cada usuário.

★ **PROCESSAMENTO EM TEMPO REAL** Ambas as plataformas processam milhões de dados por segundo para decisões instantâneas.

Reflexão Prática



O que todos esses cases têm em comum?

A Ciência de Dados é o denominador comum!

01

Coleta & Tempo Real

Estas empresas coletam dados massivos de milhões de usuários continuamente e processam informações em tempo real.

02

Inteligência Preditiva

Todas utilizam algoritmos de machine learning para previsões e tomam decisões automatizadas baseadas em dados.

03

Valor & Competitividade

Transformam dados brutos em vantagem competitiva, gerando bilhões em receita e melhores experiências.

O que é Ciência de Dados?



Definição Formal

"Ciência de Dados é um campo interdisciplinar que usa métodos científicos, processos, algoritmos e sistemas para extrair conhecimento e insights de dados estruturados e não estruturados."

A intersecção dessas áreas forma o cientista de dados completo, capacitando-o a traduzir dados brutos em decisões estratégicas acionáveis.

Componentes Fundamentais

Os Três Pilares

1

Matemática e Estatística

Fornecem toda a base analítica rigorosa para os modelos.

2

Computação e Programação


Utilização de Python, R e SQL para manipulação eficiente de dados.

3

Conhecimento de Domínio

Essencial para a interpretação correta e geração de valor real.

A Pirâmide DIKW e o Valor dos Dados



The DIKW Hierarchy

Aplicações Práticas da Evolução

DADOS (Brutos e sem contexto)

Fatos puros, como números isolados sem qualquer significado inicial.

- **Exemplo Clima:** "25, 30, 28"
- **Exemplo Saúde:** "150, 160, 155"

INFORMAÇÃO (Dados com significado)

Dados organizados que passam a transmitir uma mensagem clara.

- **Exemplo Clima:** "Temperaturas em °C de uma semana"
- **Exemplo Saúde:** "Batimentos cardíacos do paciente"

CONHECIMENTO (Identificação de padrões)

Interpretação da informação que gera aprendizado e diagnóstico.

- **Exemplo Clima:** "Média de 27.6°C indica clima tropical"
- **Exemplo Saúde:** "Paciente apresenta quadro taquicárdico"

SABEDORIA (Aplicação prática das conclusões)

Tomada de decisão estratégica e ação baseada no conhecimento.

- **Exemplo Clima:** "Definir setembro como melhor época para o plantio"
- **Exemplo Saúde:** "Encaminhar o paciente ao cardiologista"



Dados Brutos vs. Informação Valiosa

DADOS BRUTOS (Fatos Sem Contexto)

- "João, 25, SP, R\$3500"
- "Maria, 32, RJ, R\$5200"
- "Pedro, 28, SP, R\$4100"

Registros isolados, desorganizados e sem nenhum tratamento analítico prévio.

INFORMAÇÃO VALIOSA (Com Contexto)

Média Salarial: R\$4.266

Média de Idade: 28,3 anos

Distribuição: 67% são de São Paulo

Destaque: Maria tem o maior salário, 48% acima de João.

A Lição Fundamental

Dados sozinhos não têm valor intrínseco. Eles precisam de análise, contexto e interpretação para se tornarem informação útil que suporta decisões.

CONCEITO

Tipologias de Dados



STRUCTURED DATA

	NAME	ID	VALUE
1	Nam1	01	300
2	Nam2	02	400
3	Nam3	03	700
4	Nam4	04	500
5	Nam5	05	600
6	Nam6	07	700
7	Nam8	08	700
8	John	10	1000

**STRUCTURED
DATA**

UNSTRUCTURED DATA



**UNSTRUCTURED
DATA**

DADOS ESTRUTURADOS

Organizados em formato tabular, como planilhas Excel, bancos SQL e CSVs. Representam uma fração crucial das bases analíticas tradicionais.

20%

DO TOTAL GLOBAL

DADOS NÃO ESTRUTURADOS

Textos, imagens, vídeos, áudio e posts em redes sociais sem organização pré-definida. Exigem inteligência e técnicas avançadas como NLP para processamento.

80%


MUNDIAL

Dados Semi-estruturados: Possuem organização flexível (JSON, XML e logs). Compreender essas classificações é vital para aplicar as técnicas corretas de análise.

O Fluxo de Trabalho em Ciência de Dados



STEP-BY-STEP WORKFLOW LOOP



As 6 Etapas Sucessivas

★ **Limpeza de dados consome 80% do tempo!**

- **1. COLETA:** Obtém dados estruturados ou brutos diretamente de APIs, sensores e bancos.
- **2. ARMAZENAMENTO:** Guarda as informações de forma segura em data lakes ou warehouses dedicados.
- **3. LIMPEZA (80% do esforço):** Trata valores ausentes, inconsistentes e padroniza os formatos.
- **4. ANÁLISE:** Explora dados e aplica modelos estatísticos refinados e machine learning.
- **5. VISUALIZAÇÃO:** Comunica os resultados de forma clara e ágil através de dashboards dinâmicos.
- **6. DECISÃO:** Transforma os insights gerados e métricas em ações estratégicas de valor.



Percorreremos todas essas etapas fundamentais ao longo deste curso prático!

O Papel do Cientista de Dados



Principais Responsabilidades

- **Preparação de Dados:** Coletar, limpar e preparar grandes volumes de dados para análises futuras.
- **Exploração Estatística:** Explorar informações profundas através de análise estatística rigorosa.
- **Modelagem Preditiva:** Construir modelos preditivos complexos utilizando algoritmos de machine learning.
- **Comunicação & Produção:** Comunicar insights cruciais para stakeholders não-técnicos e implantar soluções em ambientes de produção.

Habilidades Necessárias

- **Programação Básica:** Domínio sólido em linguagens como Python, R e consultas em SQL.
- **Estatística & ML:** Sólido conhecimento de estatística avançada e algoritmos de machine learning.
- **Visualização & Negócios:** Técnicas avançadas de visualização de dados e compreensão profunda do contexto de negócio.
- **Storytelling:** Capacidade indispensável para traduzir modelos analíticos complexos em narrativas compreensíveis e totalmente acionáveis para a liderança.

Carreira em Ciência de Dados: Projeção & Salários



+35%

Crescimento Projetado (2024-2026)

Salários no Brasil & Mercado

- Inicial: R\$ 5.000 a R\$ 8.000 | Pleno: R\$ 10.000 a R\$ 15.000
- Sênior: R\$ 15.000 a R\$ 25.000+ | EUA: US\$ 125.000 anuais (Média)
- Menor taxa de desemprego tech (Cientista, Analista, Engenheiro)
- Contratantes: Nubank, iFood, Amazon, Google, Netflix e mais

Análise de Competências em 2024



Linguagens Essenciais

A análise de vagas revela as ferramentas indispensáveis no mercado atual.

85%

Python
Linguagem essencial absoluta.

78%

SQL
Altamente requisitado em banco de dados.

Tecnologia & Dados

Competências de ponta muito procuradas para estruturação e inovação tecnológica.

65%

Machine Learning
Demanda para modelos inteligentes.

60%

Visualização de Dados
Essencial para geração de insights (60%).
Cloud Computing em 55%.

Soft Skills

Habilidades comportamentais são extremamente valorizadas e garantem um perfil competitivo:

- **Comunicação clara:** Essencial para o alinhamento em todos os níveis.
- **Resolução criativa:** Capacidade de solucionar novos problemas desafiadores.
- **Trabalho em equipe:** Cooperação multidisciplinar.
- **Curiosidade intelectual:** Busca constante por aprendizado e novas ideias.
- **Pensamento crítico:** Análise profunda de cenários e tomadas de decisão.

Frentes em Ciência de Dados



THE DATA ECOSYSTEM



DATA SCIENTIST

DATA ANALYST

DATA ENGINEER

Analista de Dados (DA)

"O que aconteceu e por quê?"

Ferramentas: SQL, Excel e Power BI | Salário: R\$ 4-10k

Cientista de Dados (DS)

"O que vai acontecer e o que devemos fazer?"

Ferramentas: Python, R e Machine Learning | Salário: R\$ 8-20k

Engenheiro de Dados (DE)

Garante a base para as análises

Ferramentas: Spark, Kafka e Cloud | Salário: R\$ 10-22k

Colaboração de Dados no E-commerce



Cenário: Loja online foca em aumentar as vendas em 30% META: +30% VENDAS

1

Infraestrutura

Engenheiro de Dados

Cria pipelines robustos para coletar dados do site em tempo real, armazena na cloud e garante o processamento contínuo.

2

Visualização

Analista de Dados

Analisa vendas por categoria, identifica produtos mais vendidos, cria dashboards de performance e detecta gargalos no funil de conversão.


3

Inteligência

Cientista de Dados

Cria sistemas de recomendação personalizados, desenvolve modelos para prever churn, otimiza preços dinamicamente e segmenta clientes.

A Ética na Ciência de Dados



Pilares Éticos & Responsabilidade

- **Privacidade & LGPD:** Regras rigorosas para a privacidade de dados pessoais no Brasil, prevendo multas de até **2% do faturamento**.
- **Viés Algorítmico:** Modelos matemáticos podem perpetuar e ampliar discriminações históricas se forem treinados com dados enviesados.
- **Transparência & Segurança:** Exige explicabilidade nas decisões automatizadas e proteção cibernética contra vazamentos.
- **Casos Reais:** Escândalos como o da **Cambridge Analytica** e vieses raciais na **Amazon** reforçam a profunda responsabilidade do cientista de dados.

ALERTA ETICO: O impacto das decisões automatizadas molda o futuro da sociedade humana.

O Stack Tecnológico




Linguagens & Ambientes

■ **Python:** Sintaxe simples e intuitiva, sendo o principal foco prático do nosso curso.

■ **R & SQL:** Linguagem R voltada para estatística e SQL para bancos de dados relacionais.

■ **Ambientes:** Google Colab (em nuvem e gratuito), além do Jupyter Notebook e VS Code.

■ **Armazenamento:** Gestão de dados efetuada em PostgreSQL, MySQL e MongoDB.



Bibliotecas Essenciais: Pandas, NumPy, Matplotlib, Seaborn & Scikit-Learn

Por Que Escolher Python?



Vantagens Notáveis

- **Sintaxe simples e legível** que facilita o aprendizado rápido.
- **Comunidade gigante** e milhares de bibliotecas gratuitas.
- **Suporte global** de gigantes como Google e Netflix.

93%

Kaggle Survey 2024

De adoção ativa entre os cientistas de dados, consagrando-se como a linguagem número um do mercado.



Java Traditional:

```
// Requer mais de 20 linhas de código...
BufferedReader csvReader = new BufferedReader(...
while ((row = csvReader.readLine()) != null) {
    String[] data = row.split(",");
}
```

Python com Pandas:

```
import pandas as pd
dados = pd.read_csv("dados.csv")

# Apenas duas linhas legíveis e diretas!
```

ALTA DEMANDA NO MERCADO

Presente em **85% de todas as vagas** de tecnologia ativas.



VANTAGENS

- **Acesso Gratuito:** Oferece recursos de GPU e TPU sem custo.
- **Zero Instalação:** Executa 100% diretamente no navegador.
- **Pré-configurado:** Pronto com pandas, numpy e scikit-learn.
- **Google Drive:** Integração nativa para salvar notebooks de forma simples.
- **Colaboração:** Permite edição colaborativa simultânea.

LIMITAÇÕES

- **Conexão Ativa:** Requer acesso constante e obrigatório à internet.
- **Sessões Temporárias:** Máquinas expiram após 12 horas de uso.

Ideal para Aprendizado

Recursos adequados para o ensino prático, amplamente utilizados na indústria e academia.

MÃO NA MASSA!

8 PASSOS PRÁTICOS PARA O SEU PRIMEIRO PROJETO

- 01 Criar uma conta Google** ou fazer login na sua conta existente.
- 02 Acessar o Google Colab** pela primeira vez no seu navegador.
- 03 Criar nosso primeiro notebook** totalmente em branco.
- 04 Executar um código Python básico** para testar o ambiente.
- 05 Importar as bibliotecas** pandas e matplotlib necessárias.
- 06 Criar um DataFrame simples** do zero para compreender a estrutura.
- 07 Explorar um dataset real** de filmes do IMDB para análise.
- 08 Gerar nosso primeiro gráfico** visual a partir do dataset.

Abram seus navegadores agora e sigam o passo a passo!

"O processo de tentativa e erro é parte fundamental do aprendizado!"

VAMOS LÁ!

Como Acessar o Google Colab



1

Passo 1

Acesse a URL

Abra seu navegador preferido e digite colab.research.google.com na barra de endereços.

2

Passo 2

Faça o Login

Entre com sua conta Google ou crie uma gratuitamente para iniciar.

3

Passo 3

Novo Notebook

Clique no botão "Novo notebook". Pronto, você está no ambiente Colab!


Dica de Sucesso

Salve este link nos favoritos para acesso rápido, utilizaremos esta ferramenta durante todo o curso. Vamos verificar se todos conseguiram acessar antes de prosseguir!



~2 MIN Tempo Estimado

Interface do Google Colab



Componentes da Usabilidade

- **Menu Superior:** Barra com opções cruciais de arquivo, edição e execução rápida.
- **Botões + Código / + Texto:** Atalhos intuitivos para inserir blocos funcionais ou documentação Markdown.
- **Células Operacionais:** Área de código para Python (Play) e exibição imediata de saídas abaixo.
- **Painel Lateral:** Gerenciamento ágil de arquivos integrados, dados e índices estruturados.

SUA VEZ DE EXPLORAR

Reservem um minuto para explorar cada elemento clicando neles!

[Explorar Agora](#)

Vamos Escrever Nosso Primeiro Código!



primeiro_passo.py

Entrada [1]

```
print("Olá, Ciência de  
Dados!")
```

Saída do Terminal

Olá, Ciência de Dados!

Clique em "+ Código" para criar uma célula nova e digite o comando exatamente como mostrado acima!

Parabéns por executar seu primeiro código Python com extremo sucesso!

A Anatomia da Função

Função Built-in A função **print()** é um comando embutido do Python projetado exclusivamente para exibir informações e textos de forma limpa na tela.

As Aspas e a String Todo texto cercado por aspas é chamado cientificamente de **string** (uma cadeia de caracteres). É ela que protege o texto da compilação do código.

Compilação Ultra Rápida

Para rodar o código instantaneamente, pressione **Ctrl+Enter** no Windows/Linux, **Cmd+Enter** no Mac, ou clique no botão **Play azul**.

Um código sem documentação perde seu valor.



ENTRADA EM MARKDOWN

Minha Primeira Análise de Dados

Notebooks bem ****documentados**** são absolutamente essenciais para:

- Compartilhar o seu trabalho
- Criar um portfólio profissional robusto
- Facilitar a manutenção futura

Dica de Uso:

Clique no botão "+ Texto" no Google Colab para criar uma célula markdown.



SAÍDA FORMATADA (GOOGLE COLAB)

Minha Primeira Análise de Dados

Notebooks bem **documentados** são absolutamente essenciais para:



Compartilhar o seu trabalho



Criar um portfólio profissional robusto



Facilitar a manutenção futura

Destaque Profissional:

Um portfólio bem estruturado com códigos documentados demonstra maturidade técnica para o mercado.

Variáveis e Tipos de Dados



exemplo_variaveis.py

```
nome = "Danilo" # String
idade = 30 # Int
altura = 1.78 # Float
estudante = True # Bool

print(f"Olá! Me chamo {nome}.")

# Saída: Olá! Me chamo Danilo.
```

Como as caixas guardam valores:

- **String (str):** Guarda textos e caracteres delimitados por aspas.
- **Inteiro (int):** Números inteiros exatos, positivos ou negativos.
- **Float:** Representa números decimais e fracionários precisos.
- **Booleano (bool):** Valores lógicos puros: verdadeiro ou falso.

DESAFIO PRÁTICO: MÃO NA MASSA!

Crie variáveis com seus dados pessoais e exiba uma frase formatada na tela.

 **2 MINUTOS**