



Aula 2: Inteligência Artificial e Machine Learning

Bem-vindos à segunda aula da disciplina de Introdução à Ciência de Dados!

// Como máquinas aprendem e fazem previsões



Boas-Vindas e Retomada: Onde Paramos?

Na Aula 1, construímos nossa base de ferramentas:

- ✓ Google Colab e fundamentos de Python.
- ✓ Manipulação de dados com Pandas e DataFrames.
- ✓ Análise Exploratória de Dados (EDA) nos datasets IMDB e Titanic.



Hoje, daremos o próximo passo:

Introdução ao Machine Learning.



Agenda da Aula

Cronograma de 90 minutos para o nosso encontro:



15 min: Retomada e Aquecimento



40 min: Fundamentos Teóricos de IA e ML



35 min: Prática - Nosso Primeiro Modelo (Titanic)

Objetivo: Compreender a teoria e aplicar na prática um algoritmo de classificação.



Quebra-gelo: Mitos e Verdades sobre IA

Vamos testar seus conhecimentos. Verdadeiro ou Falso?



MITO

1. A IA já possui consciência própria e emoções.



VERDADE

2. Machine Learning é apenas estatística aplicada.



MITO

3. Modelos de IA não têm preconceitos, pois são puramente matemáticos.



VERDADE

4. Deep Learning é uma subárea do Machine Learning.



MITO

5. Toda IA precisa de internet para funcionar.



Discussão: Onde você viu IA hoje?

Atividade de 3 minutos

Liste interações diárias que você teve com Inteligência Artificial desde que acordou.



Tempo de Discussão

Brainstorming Rápido

Pense na sua rotina matinal até o momento.

Exemplos comuns



Reconhecimento facial no celular



Rotas otimizadas no GPS



Filtros em redes sociais



Recomendações de música



Filtro de spam no e-mail



Expectativas da Aula


Queremos conhecer o perfil da turma!



Perguntas Diagnósticas

- 01** Qual seu nível de conforto com programação Python?
- 02** O que você mais espera aprender sobre Inteligência Artificial hoje?
- 03** Você já treinou algum modelo de Machine Learning antes?

Acesse o Formulário



Ou acesse via link:

bit.ly/diagnostico-ia-aula



Conexão com a Aula Anterior

Da Análise Exploratória à Análise Preditiva

Passado (EDA)

- O que aconteceu?
- Por que aconteceu?
- Foco em estatística descritiva e visualização de dados.



Futuro (Machine Learning)

- O que vai acontecer?
- Como podemos automatizar decisões?
- Foco em padrões, algoritmos e generalização.



Objetivos de Aprendizagem

Ao final desta aula, você será capaz de:

1. **Diferenciar** Inteligência Artificial, Machine Learning e Deep Learning.
2. **Explicar** a diferença entre aprendizado supervisionado e não-supervisionado.
3. **Compreender** a mudança de paradigma da programação tradicional para ML.
4. **Treinar e avaliar** um modelo básico de classificação usando Python e Scikit-learn.



O que é Inteligência Artificial?



"A ciência e engenharia de criar máquinas inteligentes, especialmente programas de computador inteligentes."

- John McCarthy, 1956 (Definição Formal)

Escopo Geral


É o campo amplo da ciência da computação focado em criar sistemas capazes de realizar tarefas que normalmente exigiriam inteligência humana, como raciocínio, aprendizado e percepção.



Breve História da IA

Uma evolução de décadas até a era moderna

- 1950** ● **Alan Turing** propõe o "Teste de Turing" para avaliar a inteligência de máquinas.
- 1956** ● **Conferência de Dartmouth**, estabelecendo o nascimento oficial da disciplina de IA.
- 1997** ● **Deep Blue (IBM)** derrota o campeão mundial de xadrez Garry Kasparov.
- 2012** ● **Revolução do Deep Learning** com o AlexNet vencendo a competição ImageNet.
- 2020+** ● **Era dos Grandes Modelos de Linguagem (LLMs)**, marcada pela chegada do ChatGPT.



Evolução Científica e Avanço Algorítmico da IA



Tipos de Inteligência Artificial

ANI

Estágio Atual

Artificial Narrow Intelligence

IA Fraca

Focada em uma única tarefa (ex: Assistentes virtuais, xadrez).

É a única que existe hoje.

AGI

Artificial General Intelligence

IA Forte

Inteligência de nível humano em qualquer tarefa cognitiva.

ASI

Artificial Superintelligence

Superinteligência

Supera o intelecto humano em praticamente todas as áreas.

Classificação por Funcionalidade: Máquinas reativas, memória limitada, teoria da mente e autoconsciência.



O que é Machine Learning?



"O campo de estudo que dá aos computadores a habilidade de aprender sem serem explicitamente programados."

— Arthur Samuel, 1959 • Definição Clássica

Definição Moderna (Tom Mitchell, 1997): Um programa aprende se sua performance melhora com a experiência.

E

Experiência

A base de dados histórico e interações que alimentam e treinam o algoritmo de aprendizado.

T

Tarefa

O objetivo prático ou problema específico do mundo real que o programa precisa resolver.

P

Performance

A métrica quantitativa para medir a precisão e a melhoria de desempenho do modelo em T devido a E.



ML vs Programação Tradicional

Mudança fundamental de paradigma

Programação Tradicional

Fluxo de Processamento:

Dados + Regras → Respostas

O programador define explicitamente a lógica por trás de cada decisão.

Exemplo: Regras estritas baseadas em condicionais estruturadas (if/else).

Inversão



Machine Learning

Fluxo de Aprendizado:

Dados + Respostas → Regras (Modelo)

O algoritmo analisa os dados históricos e os exemplos rotulados para construir as regras matemáticas.

O modelo gerado é então capaz de generalizar e inferir regras sobre novos dados.



Aprendizado Supervisionado: O Mais Comum

Conceito Central

O modelo aprende a partir de dados rotulados. É como estudar com um gabarito.


Características

- Conhecemos a resposta correta (Target) durante o treinamento.
- O algoritmo tenta minimizar o erro entre sua previsão e o rótulo real.

Divisão Principal

1. Classificação: Prever categorias discretas (ex: Sim/Não, Gato/Cachorro).

2. Regressão: Prever valores numéricos contínuos (ex: Preço, Temperatura).



Exemplos de Classificação

Previsão de categorias discretas ou classes:



Filtro de Spam

Classificar e-mails como 'Spam' ou 'Não Spam'.



Diagnóstico Médico

Prever se um tumor é 'Maligno' ou 'Benigno' com base em exames.



Análise de Sentimento

Identificar se um comentário de cliente é 'Positivo', 'Neutro' ou 'Negativo'.



Aprovação de Crédito

Decidir se um empréstimo deve ser 'Aprovado' ou 'Negado'.



Exemplos de Regressão

Previsão de valores contínuos ou quantidades:



Mercado Imobiliário

Prever o preço exato de uma casa com base em sua área, localização e número de quartos.

Preço estimado (R\$)



Previsão de Vendas

Estimar o faturamento em reais de uma loja no próximo mês.

Faturamento em Reais



Meteorologia

Prever a temperatura em graus Celsius para amanhã.

Temperatura em °C



Recursos Humanos

Estimar o salário adequado para um profissional com base em sua experiência.

Salário Ideal (R\$)



Aprendizado Não-Supervisionado


Conceito Central

O modelo explora dados sem rótulos (sem gabarito) para encontrar padrões ocultos e estruturas intrínsecas.

Aplicações Principais

- **Clusterização (Agrupamento):** Segmentação de clientes com base em comportamento de compra (K-Means).
- **Redução de Dimensionalidade:** Simplificar datasets complexos preservando a informação principal (PCA).
- **Deteção de Anomalias:** Identificar fraudes em cartões de crédito por comportamento fora do padrão.

PROCESSO DE AGRUPAMENTO (CLUSTERING)



Aprendizado por Reforço

Conceito Central: Um agente aprende a tomar decisões interagindo com um ambiente, recebendo recompensas (acertos) ou punições (erros).

Características

- Baseado em tentativa e erro para maximizar a recompensa cumulativa ao longo do tempo.

Exemplos de Aplicação

- **AlphaGo (Google DeepMind):** IA que derrotou o campeão mundial do jogo Go.
- **Robótica:** Ensinar robôs a andar ou manipular objetos.
- **Carros Autônomos:** Navegação e tomada de decisão no trânsito.

Ciclo de Aprendizado por Reforço



O que é Deep Learning?

Conceito Central

Subárea do Machine Learning que utiliza Redes Neurais Artificiais profundas, inspiradas na estrutura do cérebro humano.


Requisitos & Características

- Exige grandes volumes de dados (**Big Data**) e alto poder computacional (**GPUs**).
- Excelente para dados não estruturados (imagens, áudio, texto natural).

Aplicações Modernas

Reconhecimento de voz (Siri/Alexa), visão computacional, tradução simultânea e IA Generativa.

Modelo de Rede Neural Profunda



Resumo: IA, ML e Deep Learning

Entendendo a hierarquia e as relações de subconjunto

1. Inteligência Artificial (IA)

O universo amplo de máquinas simulando inteligência humana.

2. Machine Learning (ML)

Subárea da IA focada em algoritmos que aprendem com dados (sem programação explícita).

3. Deep Learning (DL)


Subárea do ML que usa redes neurais profundas para resolver problemas altamente complexos.





Mão na Massa

Nosso Primeiro Modelo!



Desafio Prático: Sobrevivência no Titanic

Objetivo:

Usar dados históricos de passageiros (**idade**, **sexo**, **classe**) para treinar um modelo capaz de prever se um passageiro sobreviveria ou não ao naufrágio.

Ferramentas que usaremos:

- **Python** — Linguagem base
- **Pandas** — Manipulação de dados
- **Scikit-learn** — Machine Learning

Importação das bibliotecas essenciais para o projeto:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# Bibliotecas de Machine Learning

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, classification_report
```



Carregando o Dataset Titanic

Vamos carregar os dados diretamente da biblioteca seaborn e fazer a inspeção inicial:

load_data.py

```
# Carregando o dataset
titanic = sns.load_dataset('titanic')

# Visualizando as primeiras linhas
display(titanic.head())

# Verificando o tamanho do dataset
print(f"Linhas e Colunas: {titanic.shape}")
```

Resultado Esperado (Console / df)

>>> Console Output:

Linhas e Colunas: (891, 15)

Index	survived	pclass	sex	age	sibsp	...
0	0	3	male	22.0	1	...
1	1	1	female	38.0	1	...
2	1	3	female	26.0	0	...
3	1	1	female	35.0	1	...
4	0	3	male	35.0	0	...



Entendendo o Problema

Definição Lógica do Problema de Classificação Binária

Target (Alvo - y)

O que queremos prever?

A coluna **survived**

0 = Não sobreviveu

1 = Sobreviveu

Features (Preditores - X)

Quais informações usaremos para prever?

- **pclass** (Classe do bilhete)
- **sex** (Gênero)
- **age** (Idade)
- **fare** (Tarifa paga)



Limpeza de Dados: Valores Missing



Modelos de ML não lidam bem com dados nulos. Precisamos tratar as lacunas:

```
# Preenchendo idades vazias com a mediana
titanic['age'] = titanic['age'].fillna(titanic['age'].median())

# Removendo a coluna 'deck' (muitos valores nulos)
titanic = titanic.drop(columns=['deck'])

# Removendo linhas restantes com valores nulos
titanic = titanic.dropna()
```



Codificação: Texto em Números



Algoritmos matemáticos precisam de números, não de palavras (strings):

```
encoder = LabelEncoder()

# Transformando 'sex' (male/female) em (1/0)
titanic['sex'] = encoder.fit_transform(titanic['sex'])

# Transformando cidade de embarque em números
titanic['embark_town'] = encoder.fit_transform(titanic['embark_town'])
```



Selecionando Features e Target

Divisão do dataset em matriz de características (X) e vetor alvo (y):

```
# Definindo as features (Preditores)
features = ['pclass', 'sex', 'age', 'fare', 'sibsp', 'parch']
X = titanic[features]

# Definindo o Target (Alvo)
y = titanic['survived']

print("Shape de X:", X.shape)
print("Shape de y:", y.shape)
```



Saída esperada: Shape de X: (891, 6) [891 instâncias, 6 características] | Shape de y: (891,) [vetor unidimensional]



Split dos Dados: Treino vs Teste

Separando os dados para avaliar o modelo com informações inéditas:

```
split_dados.py

# Divisão 80% para treino e 20% para teste
X_train, X_test, y_train, y_test =
train_test_split(
X, y,
test_size=0.20,
random_state=42,
stratify=y
)
```

Visualização da Partição (Split)

Dataset Original 100%



Treino 80%

20%

Treino (80%): Onde o modelo aprende os padrões e as relações entre as features.

Teste (20%): Onde validamos se o modelo realmente aprendeu ou se apenas decorou (overfitting).



Criar e Treinar o Modelo

Instanciando e treinando o algoritmo Random Forest:

```
# Instanciando o modelo
modelo_rf = RandomForestClassifier(
    n_estimators=100, random_state=42
)

# Treinando o modelo (O aprendizado acontece aqui!)
modelo_rf.fit(X_train, y_train)

print("Modelo treinado com sucesso!")
```

💡 CONSELHO PRÁTICO

O método .fit() é o coração do algoritmo de aprendizado. É nele que as 100 árvores de decisão começam a mapear os padrões dos seus dados.

Reprodutibilidade: Definir o parâmetro `random_state=42` garante consistência exata nos resultados de execuções futuras do mesmo notebook.

Escalabilidade: O parâmetro `n_estimators=100` cria 100 estimadores em paralelo, melhorando a precisão geral.



Fazendo Previsões e Avaliação

Testando o modelo com os 20% de dados separados e medindo a precisão:

```
# Fazendo previsões nos dados de teste
previsoes = modelo_rf.predict(X_test)

# Calculando a acurácia (taxa de acerto)
acuracia = accuracy_score(y_test, previsoes)
print(f"Acurácia do Modelo: {acuracia * 100:.2f}%")

# Relatório detalhado
print(classification_report(y_test, previsoes))
```

82%

Acurácia Esperada

Desempenho de referência típico esperado deste algoritmo utilizando a proporção de 20% para teste.

